

OpenPlay Profiler

Propuesta de visualización analítica para identificar perfiles exploratorios
de jugadores

Informe del proyecto

Autores: Juan José Huamaní Vásquez
Zela Flores Gabriel Frank
Tema: Visualización analítica y ciencia de datos
Dataset: OpenPlay

13 de julio de 2026

Índice

1. Introducción	3
2. Trabajos relacionados	3
2.1. Trabajos relacionados con modelos y métodos	4
2.2. Trabajos relacionados con visualización analítica	4
2.3. Vacío identificado y aporte propio	5
3. Modelos	6
3.1. Vector de características	7
3.2. Estandarización e imputación	8
3.3. Correlación	8
3.4. PCA	8
3.5. UMAP	9
3.6. t-SNE	9
3.7. Clustering	9
3.8. Conceptos usados, explicados de forma simple	9
4. Descripción general del sistema / Overview	10
4.1. Descripción de los datos	11
4.2. Preprocesamiento	12
4.3. Preguntas guía del análisis	13
4.4. Tareas de análisis	13
4.5. Pipeline del sistema	15
5. Diseño visual	16
5.1. Por qué las representaciones visuales permiten descubrir conocimiento . . .	17
5.2. Vistas del sistema	17
5.3. Coordinación entre vistas	25
5.4. Recorrido cognitivo para descubrir conocimiento	26
6. Discusión, estudios de caso y validación	26
6.1. Caso de estudio 1: cobertura de datos y confiabilidad del análisis	29
6.2. Caso de estudio 2: juego nocturno e intensidad de actividad	30
6.3. Caso de estudio 3: bienestar, riesgo y uso registrado	31
6.4. Caso de estudio 4: perfil multiplataforma con alta cobertura	33

6.5. Validación de la propuesta visual	34
7. Matriz de cumplimiento de la rúbrica	35
8. Uso responsable de herramientas de inteligencia artificial	36
9. Conclusiones	36
10.Referencias	37

Resumen

Este informe presenta *OpenPlay Profiler*, una herramienta para estudiar datos de jugadores de OpenPlay. Reúne variables de bienestar, riesgo de juego problemático, actividad registrada, cognición y uso del tiempo. La herramienta compara participantes, forma grupos con características parecidas y muestra qué variables explican las diferencias. El aporte no es solo generar gráficos: cada resultado se comprueba con otra vista y con los valores originales.

Palabras clave: OpenPlay, videojuegos, bienestar digital, visualización analítica, PCA, UMAP, t-SNE, clustering, perfiles exploratorios.

1. Introducción

Los videojuegos son una actividad digital masiva y generan datos sobre frecuencia de uso, plataformas, sesiones, horarios y respuestas de los usuarios. En este contexto, el estudio OpenPlay recopila telemetría de juego de plataformas como Nintendo Switch, Steam y Xbox, junto con medidas psicológicas y de bienestar como WEMWBS, PROMIS, GDT y BANGS, además de variables de motivación y cognición [1]. Además, la Organización Mundial de la Salud define el trastorno por videojuegos como un patrón de comportamiento caracterizado por control deteriorado, prioridad creciente del juego y continuidad pese a consecuencias negativas [2]. Por ello, analizar datos de juego y bienestar es un problema relevante tanto a nivel social como computacional.

El problema consiste en identificar perfiles de jugadores usando varias variables al mismo tiempo. Un perfil exploratorio es un grupo inicial de participantes con valores parecidos. Sirve para describir y formular nuevas preguntas, no para diagnosticar personas. También se buscan casos alejados del comportamiento general, por ejemplo, participantes con sesiones nocturnas muy superiores al resto.

Para abordar el problema se construye un vector de características por participante. Este vector integra variables demográficas, bienestar, riesgo de juego problemático, telemetría, actividad diaria, cognición y uso del tiempo. La selección de estas dimensiones responde a la estructura del dataset OpenPlay y permite comparar participantes usando una representación común. Antes del agrupamiento, las variables se revisan y estandarizan para reducir el efecto de escalas diferentes y facilitar la comparación entre atributos.

El objetivo del proyecto es identificar y caracterizar perfiles exploratorios de jugadores en OpenPlay mediante reducción dimensional y clustering. La herramienta *OpenPlay Profiler* se usa como apoyo para ejecutar el flujo de análisis, observar la proyección bidimensional y comparar los grupos encontrados. Los resultados no se presentan como diagnósticos clínicos, sino como agrupamientos exploratorios que pueden servir a investigadores, analistas de comportamiento y diseñadores de experiencias digitales para formular hipótesis sobre patrones de juego y bienestar.

2. Trabajos relacionados

Los trabajos relacionados se agrupan en dos líneas: estudios sobre datos de videojuegos y bienestar, y propuestas de visualización analítica para datos multivariados. Esta revisión

no busca cubrir toda la literatura, sino ubicar el proyecto dentro de enfoques cercanos y justificar por qué una herramienta visual interactiva es pertinente para el problema.

2.1. Trabajos relacionados con modelos y métodos

El estudio OpenPlay plantea una base de datos longitudinal que combina trazas digitales de juego con medidas psicológicas y cognitivas [1]. Su importancia para este proyecto está en que no limita el análisis a una sola fuente: incluye plataformas, encuestas, tareas cognitivas y uso del tiempo. Esa estructura exige técnicas capaces de integrar variables heterogéneas y revisar la cobertura de cada fuente antes de interpretar resultados.

La Organización Mundial de la Salud define el trastorno por videojuegos en la CIE-11 como un patrón persistente de comportamiento de juego con deterioro del control, prioridad creciente y continuidad pese a consecuencias negativas [2]. Esta referencia no se usa para diagnosticar participantes, sino para justificar que el análisis de patrones de juego y bienestar tiene relevancia social y debe tratarse con cuidado metodológico.

En cuanto a métodos, PCA, UMAP y t-SNE son técnicas utilizadas para representar datos de muchas dimensiones en espacios de menor dimensión [6, 7, 8]. Su función en este proyecto es permitir una lectura visual de similitudes entre participantes. El clustering, especialmente K-means, complementa esa proyección al separar grupos preliminares que luego deben interpretarse con variables originales [9].

2.2. Trabajos relacionados con visualización analítica

La visualización analítica combina representaciones visuales, interacción humana y métodos computacionales para apoyar el razonamiento sobre datos complejos [3]. Heer y Shneiderman destacan que la interacción es esencial para explorar, filtrar, seleccionar y conectar vistas durante el proceso de análisis [4]. Este enfoque se relaciona directamente con OpenPlay Profiler, porque el usuario no solo observa una proyección 2D: también selecciona participantes, revisa variables originales, aplica filtros, compara grupos y valida si un patrón aparece en varias vistas.

Tabla 1: Tabla comparativa de trabajos relacionados

Referencia	Problema	Método o enfoque	Relación con el proyecto
Ballou et al. / OpenPlay	Relación entre juego, bienestar, motivación y cognición	Dataset longitudinal con telemetría multiplataforma y encuestas	Proporciona la fuente de datos y justifica integrar varias dimensiones del jugador.
OMS / CIE-11	Definición de trastorno por videojuegos	Marco clínico y social sobre conducta de juego problemática	Motiva el análisis responsable sin convertir clusters en diagnósticos.
Jolliffe; McInnes et al.; van der Maaten y Hinton	Representación de datos multivariados	PCA, UMAP y t-SNE para reducción dimensional	Sustentan la proyección 2D usada para explorar similitud entre participantes.
MacQueen	Agrupamiento de observaciones	K-means para clustering	Permite formar perfiles exploratorios que luego se interpretan con variables originales.
Keim et al.; Heer y Shneiderman	Análisis visual interactivo	Visual analytics e interacciones coordinadas	Sustentan el diseño de vistas conectadas para validar patrones.

2.3. Vacío identificado y aporte propio

Los trabajos revisados cubren partes separadas del problema. OpenPlay aporta el dataset y muestra la importancia de estudiar juego y bienestar; PCA, UMAP, t-SNE y K-means aportan métodos para representar o agrupar datos; y los trabajos de análisis visual explican el valor de la interacción. Sin embargo, estas referencias no ofrecen para este dataset una herramienta que conecte, en un mismo recorrido, el control de cobertura, la construcción del vector, la formación de perfiles y la comprobación con variables originales.

El aporte propio de OpenPlay Profiler es unir esas etapas. La herramienta permite saber de qué variables sale cada gráfico, distinguir comportamiento de cantidad de datos disponibles y comprobar un posible patrón en una segunda vista. Por ejemplo, un grupo separado en PCA no se acepta como resultado final: primero se identifican las variables que lo diferencian y luego se revisan en dispersión, barras, encuestas o filtros. Esta conexión entre calidad de datos, descubrimiento y comprobación constituye el aporte del proyecto frente a los trabajos revisados.

3. Modelos

El proyecto no utiliza modelos predictivos ni clasificadores supervisados, porque no existe una etiqueta clínica que se busque predecir. El objetivo es exploratorio: construir una representación común de cada participante, proyectarla visualmente, detectar perfiles y explicar esos perfiles con variables originales. Por esa razón, los modelos se usan como apoyo para la visualización analítica y no como mecanismos automáticos de diagnóstico.

En esta sección se describen los modelos como componentes del sistema: qué reciben, qué transforman y qué entregan a las vistas. Las imágenes de resultados se reservan para la sección de validación, donde se muestran como evidencia de los casos de estudio.

Tabla 2: Resumen de modelos y su relación con la validación

Técnica	Entrada	Salida	Uso en la herramienta
Vector de características	Variables numéricas seleccionadas	Representación por participante	Define qué atributos participan en PCA, UMAP, t-SNE y clustering.
Estandarización e imputación	Vector con escalas distintas y faltantes	Matriz numérica comparable	Evita que una variable domine por escala y permite trabajar con cobertura parcial.
Correlación	Pares de variables numéricas	Matriz o pares con asociación alta	Detecta redundancia y ayuda a defender la selección del vector.
PCA / UMAP / t-SNE	Vector estandarizado	Coordenadas 2D por participante	Genera la proyección visual donde se localizan perfiles o casos.
Clustering	Vector original estandarizado	Etiqueta oficial de grupo por participante	Forma perfiles compartidos que PCA, Bivariado y Validación reutilizan e interpretan con variables originales.

Tabla 3: Flujo conceptual de los modelos en OpenPlay Profiler

Etapa	Operación	Resultado dentro del sistema
Dataset consolidado	Carga de <code>openplay_consolidated.csv</code> y lectura de columnas disponibles	Matriz inicial de participantes, variables y banderas de fuente.
Vector de características	Selección del vector recomendado o de un vector definido por el usuario	Submatriz numérica que representa a cada participante.
Preprocesamiento	Imputación de faltantes y estandarización de escalas	Matriz comparable para cálculo de similitud.
Reducción dimensional	PCA, UMAP o t-SNE sobre el vector preparado	Coordenadas 2D para ubicar participantes en la vista interactiva.
Clustering	K-means, jerárquico o DBSCAN según la configuración elegida	Etiquetas de perfil exploratorio y métricas descriptivas.
Interpretación	Comparación con variables originales y vistas coordinadas	Explicación de perfiles, anomalías y patrones validados.

3.1. Vector de características

El vector de características es la representación numérica de cada participante. En este proyecto integra variables de varias dimensiones: edad y plataformas, escalas de bienestar y riesgo, sesiones de juego, actividad nocturna, juegos únicos, registros diarios, medidas cognitivas y uso del tiempo. Su utilidad es convertir datos de origen distinto en una matriz comparable para los modelos.

El vector se conecta con las visualizaciones porque determina la posición de cada participante en PCA, UMAP o t-SNE. Si el vector se modifica, también cambia la proyección y la lectura de clusters. Por esa razón la herramienta incluye una vista de evaluación del vector, donde se revisa si las variables elegidas son numéricas, si tienen cobertura suficiente y si existen correlaciones altas que puedan generar redundancia. En los casos de estudio, el vector permite combinar telemetría, bienestar y uso del tiempo en una misma lectura visual.

El vector recomendado que aparece en la herramienta se carga desde el propio proyecto y se resume en la Tabla 4. Este vector funciona como configuración inicial para la exploración, aunque la interfaz permite agregar o quitar variables antes de ejecutar reducción dimensional o clustering.

Tabla 4: Vector de características recomendado por OpenPlay Profiler

Dimensión	Variables incluidas
Demografía y plataformas	age, num_platforms, num_telemetry_platforms, self_reported_weekly_play.
Bienestar y riesgo	gdt_total, promis_total, wemwbs_total, bangs_total.
Telemetría de juego	telem_nocturnal_sessions, steam_playtime_2weeks_max, steam_playtime_forever_max, steam_unique_games, steam_owned_games_count.
Actividad diaria	daily_played_days, daily_stress_days.
Cognición	cog_mean_accuracy, cog_mean_rt.
Uso del tiempo	timeuse_gaming_entries, timeuse_num_days.

3.2. Estandarización e imputación

Antes de aplicar reducción dimensional se estandarizan las variables numéricas. Esto evita que variables con escalas grandes, como minutos de juego o tiempos de respuesta, dominen sobre variables con escalas pequeñas, como puntajes de encuestas. Para los valores faltantes, la herramienta permite imputación por media, imputación con cero o eliminación de casos, de modo que el usuario pueda evaluar cómo cambia la proyección según el tratamiento elegido.

En la herramienta, la estandarización y el tratamiento de valores faltantes se aplican antes de la reducción dimensional y el clustering. Esta decisión permite comparar variables de escalas distintas y evita que las sesiones o minutos de juego oculten las diferencias en escalas como PROMIS, WEMWBS, GDT o BANGS.

3.3. Correlación

La correlación se usa para revisar relaciones entre variables numéricas y detectar redundancia. En la herramienta, la matriz de correlación no elimina automáticamente variables, pero advierte pares con relación alta. Esto ayuda a decidir si el vector está demasiado concentrado en una misma familia de medidas o si representa dimensiones distintas del problema.

La correlación también cumple una función de validación: cuando una separación visual se plantea como relación entre dos variables, la vista bivariada y la matriz de correlación permiten revisar si esa relación tiene respaldo en los valores originales. Esto es relevante para el Caso 2, donde las sesiones totales y nocturnas se analizan juntas.

3.4. PCA

PCA, o análisis de componentes principales, transforma un conjunto de variables correlacionadas en componentes lineales que concentran la mayor variabilidad posible [6]. En el sistema se utiliza para proyectar participantes en dos ejes interpretables como componentes principales. El resultado es un mapa donde la cercanía entre puntos indica similitud

aproximada según el vector seleccionado. La herramienta también reporta la varianza explicada, lo que permite saber si la vista 2D conserva suficiente información para apoyar una lectura exploratoria.

En la validación del informe, PCA se usa como mapa de referencia para ubicar los perfiles C0, C1, C2 y C3. Sin embargo, la conclusión no depende solo de la ubicación de los puntos: cada grupo se explica después mediante medias estandarizadas, cobertura por fuente y relaciones bivariadas.

3.5. UMAP

UMAP construye una representación de baja dimensión conservando relaciones de vecindad entre observaciones [7]. En este proyecto se usa para observar grupos locales de participantes que tienen combinaciones similares de bienestar, telemetría, cognición y uso del tiempo. Sus parámetros, como número de vecinos y distancia mínima, permiten modificar el nivel de separación visual. El conocimiento que aporta es la identificación de zonas de similitud, separaciones entre perfiles y posibles puntos atípicos.

UMAP es útil durante la exploración interactiva porque puede separar vecindarios locales que PCA no siempre separa. Aun así, cualquier patrón encontrado con UMAP debe confirmarse con variables originales, filtros y vistas bivariadas para evitar interpretar una forma visual como evidencia suficiente.

3.6. t-SNE

t-SNE es una técnica de reducción dimensional que busca preservar vecindades locales en una proyección de baja dimensión [8]. En la herramienta funciona como alternativa a PCA y UMAP. Su valor está en comparar si los grupos locales se mantienen cuando se usa otro método de proyección. Si un patrón aparece en una proyección y también se revisa con variables originales o con otra vista, la interpretación gana solidez.

3.7. Clustering

El clustering agrupa participantes según qué tan parecidos son. OpenPlay Profiler incluye K-means, agrupamiento jerárquico y DBSCAN. K-means coloca cada participante en el grupo cuyo centro está más cerca y vuelve a calcular esos centros hasta que los grupos dejan de cambiar [9]. DBSCAN forma grupos donde hay muchos puntos cercanos y puede dejar casos aislados fuera. El método jerárquico une primero los puntos más cercanos. La herramienta también muestra medidas sencillas para comparar si los grupos están compactos, separados y equilibrados en tamaño.

3.8. Conceptos usados, explicados de forma simple

- **Vector de características:** lista de variables que representa a cada participante, como edad, sesiones, escalas y plataformas.

- **Estandarizar:** cambiar las variables a una escala comparable para que una variable con números grandes no domine solo por su unidad.
- **Imputar:** completar un dato faltante con una regla, como la media o la mediana. Permite calcular, pero puede influir en el resultado.
- **PCA:** resumir muchas variables en dos ejes para dibujar a los participantes. Puntos cercanos tienen valores parecidos en el vector elegido.
- **K-means:** formar una cantidad indicada de grupos según cercanía. En este proyecto se usaron cuatro como configuración exploratoria.
- **Correlación:** indicar si dos variables tienden a subir o bajar juntas. No demuestra que una cause a la otra.
- **Cobertura:** porcentaje de participantes con datos de una fuente. Una fuente con baja cobertura exige mayor cautela.

En la validación se usa clustering para organizar participantes en perfiles exploratorios. El cluster no se interpreta por su color, sino por las variables que lo diferencian: cobertura multiplataforma, intensidad nocturna, bienestar/riesgo y uso registrado. De esta forma, el modelo cumple una función de descubrimiento visual, mientras que la explicación se sostiene en las vistas de confirmación.

4. Descripción general del sistema / Overview

OpenPlay Profiler está organizado como una aplicación web interactiva para convertir datos heterogéneos de juego y bienestar en evidencia visual verificable. El usuario carga el dataset consolidado o archivos fuente, revisa la calidad de los datos, selecciona variables, evalúa el vector, aplica reducción dimensional, ejecuta clustering y valida patrones mediante vistas conectadas. La propuesta no termina en la generación de una proyección 2D: el flujo obliga a revisar cobertura, variables originales y casos de estudio antes de formular conclusiones.




Figura 1: Vista general de OpenPlay Profiler con el dataset consolidado cargado. La pantalla inicial resume participantes, variables, cobertura por fuente y vista previa del dataset.

4.1. Descripción de los datos

La fuente principal es el dataset OpenPlay, consolidado en el archivo `openplay_consolidated.csv`. La copia pública minimizada contiene 2544 participantes y 171 variables. De ellas, 129 se tratan como numéricas y 42 como categóricas dentro del sistema. El porcentaje promedio de valores faltantes es 53.7 %. Este dato no se interpreta como resultado del comportamiento de los jugadores, sino como una condición de calidad que afecta la lectura visual: antes de explicar perfiles, el usuario debe saber qué fuentes tienen suficiente cobertura.

Las fuentes integradas incluyen encuestas de ingreso, encuestas biweekly, encuestas diarias, telemetría de Steam, Xbox, Nintendo Switch, Android e iOS, tareas cognitivas y registros de uso del tiempo. Las variables principales se agrupan de la siguiente manera:

- **Demografía minimizada y base del participante:** edad generalizada, género, país, plataformas declaradas y cobertura de telemetría.
- **Bienestar y salud mental:** puntajes como WEMWBS y PROMIS.
- **Riesgo de juego problemático:** GDT y BANGS.
- **Telemetría de juego:** sesiones totales, sesiones nocturnas, duración de sesiones, juegos únicos y tiempo de juego en Steam.

- **Actividad diaria:** días con registros, días jugados y reportes asociados a la actividad.
- **Cognición:** tiempo de respuesta promedio, precisión promedio, número de tareas y ensayos.
- **Uso del tiempo:** número de entradas, días registrados y entradas relacionadas con videojuegos.

El dataset contiene muchas variables de distintos tipos y varias resumen actividad durante periodos de tiempo. Las banderas de disponibilidad indican si existe información de cada fuente. Son importantes porque ayudan a diferenciar un posible comportamiento de una separación producida simplemente porque algunos participantes tienen más datos disponibles.

Tabla 5: Cobertura por fuente en el dataset consolidado

Fuente o bandera	Participantes con datos	Cobertura
Biweekly	1596	62.7 %
Daily	1230	48.3 %
Steam	2039	80.1 %
Xbox	277	10.9 %
Nintendo Switch	726	28.5 %
Android	73	2.9 %
iOS	93	3.7 %
Cognición	1453	57.1 %
Uso del tiempo	1134	44.6 %

4.2. Preprocesamiento

El preprocesamiento se concentra en preparar datos para análisis visual, no en producir un análisis estadístico cerrado. Primero se integran las fuentes por identificador de participante. Antes del despliegue se ejecuta una sanitización reproducible: se eliminan identificadores, geografía aproximada, medidas corporales, demografía detallada y respuestas sensibles de neurodiversidad; se reemplaza el identificador interno por un consecutivo, se redondea la edad a intervalos de cinco años y se agrupan categorías con menos de diez participantes. Esta minimización reduce el riesgo, pero no sustituye una evaluación legal y formal de reidentificación. Luego se generan variables derivadas, como sesiones totales, sesiones nocturnas, juegos únicos, minutos de juego, conteos de registros y banderas de disponibilidad. Después se revisan tipos de datos, valores faltantes, distribuciones y cobertura. Esta etapa responde directamente al Caso 1, porque la cobertura de datos condiciona la fuerza de cualquier interpretación posterior.

Para la reducción dimensional, solo se usan variables numéricas. Las variables categóricas se conservan para filtrar, describir e interpretar participantes, pero no entran directamente al cálculo de PCA, UMAP o t-SNE. Las variables seleccionadas se estandarizan y se tratan los valores faltantes según el método elegido. Finalmente, las coordenadas 2D y las etiquetas de clustering se conectan con las vistas de selección, tablas y perfiles.

La interpretación final no se basa solamente en la posición de los puntos, sino en la combinación entre proyección, diferencias estandarizadas, filtros y gráficos de validación.

4.3. Preguntas guía del análisis

Las tareas del sistema se formularon a partir de preguntas concretas que sí pueden responderse con las vistas implementadas en OpenPlay Profiler. De esta forma, ninguna tarea queda desconectada de la interfaz ni de los datos reales del proyecto.

- **P1.** ¿Qué fuentes de OpenPlay tienen suficiente cobertura para sostener una interpretación visual y cuáles deben leerse con cautela?
- **P2.** ¿Qué relaciones entre telemetría, bienestar, riesgo y uso del tiempo explican diferencias entre participantes?
- **P3.** ¿Qué perfiles exploratorios aparecen al combinar el vector de características con reducción dimensional y clustering, y cómo se validan con variables originales?

4.4. Tareas de análisis

La formulación sigue la abstracción de tareas propuesta por Munzner [5]. Cada tarea separa el *por qué* del análisis del *cómo* de la interfaz. El porqué se describe mediante cuatro elementos: la acción general (descubrir, comprobar o producir un dato derivado), el tipo de búsqueda, el alcance de la consulta y el objetivo buscado en los datos. En cambio, hacer clic, seleccionar con lazo, filtrar, cambiar ejes o ejecutar K-means son interacciones y métodos que apoyan la tarea; no son la tarea por sí mismos.

Tabla 6: Preguntas, tareas y vistas que las responden

Tarea	Pregunta	Objetivo analítico	Vista y evidencia visual
T1	P1	Descubrir qué fuentes y variables tienen evidencia suficiente y cuáles requieren cautela.	Datos, profiling y filtros. Se observa en la Figura 3 y se valida con la Figura 11.
T2	P2	Comparar variables para reconocer relaciones o información repetida y derivar un vector defendible del participante.	Vector, profiling, encuestas y bivariado. Se observa en las Figuras 7, 6 y 5.
T3	P3	Explorar similitudes entre participantes para localizar perfiles y posibles casos atípicos.	Reducción dimensional y clustering. Se observa en la Figura 9.
T4	P1–P3	Comprobar qué variables caracterizan cada perfil y si la interpretación se mantiene al controlar cobertura.	Validación, filtros, perfil de clusters y cobertura por grupo. Se observa en las Figuras 10, 13 y 14.

Tabla 7: Abstracción de tareas según el marco de Munzner

Tarea	Acción de análisis	Búsqueda	Consulta	Objetivo en los datos
T1	Consumir: descubrir	Explorar: al inicio no se conoce qué fuente será suficiente	Resumir todas y comparar algunas	Distribuciones de faltantes, cobertura y valores extremos por fuente o variable.
T2	Consumir: descubrir; producir: derivar el vector	Explorar relaciones y luego localizar pares conocidos	Comparar variables y resumir su aporte	Correlaciones, distribuciones y similitud entre atributos que podrían repetir información.
T3	Consumir: descubrir	Explorar participantes sin conocer de antemano el perfil ni su posición	Resumir el conjunto; luego identificar y comparar grupos o casos	Similitudes, agrupamientos, separaciones y casos atípicos.
T4	Consumir: comprobar una posible explicación	Localizar el perfil ya identificado y revisar sus integrantes	Comparar el perfil con los demás y resumir sus rasgos	Características del perfil, relaciones entre variables y efecto de la cobertura.

Las tareas forman una cadena. T1 determina qué evidencia puede usarse; T2 produce la representación que sirve como entrada de T3; T3 genera candidatos a perfil; y T4 comprueba o rechaza su interpretación. Así se evita presentar PCA, clustering o filtros como fines independientes.

Tabla 8: Justificación completa de las tareas analíticas

Tarea	Por qué es necesaria	Conocimiento que produce	Vínculo con el objetivo
T1	La cobertura cambia mucho entre fuentes. Sin revisarla, un grupo podría reflejar participantes con más datos y no un comportamiento diferente.	Identifica qué fuentes sostienen comparaciones y cuáles requieren cautela; por ejemplo, Steam tiene mayor cobertura que Android, iOS o Xbox.	Permite caracterizar perfiles sin confundir intensidad de juego con disponibilidad de información.
T2	El participante está descrito por variables de escalas y fuentes distintas. Es necesario decidir cuáles entran al vector y si aportan información repetida.	Explica qué relaciones existen entre bienestar, riesgo, telemetría y uso del tiempo, y qué variables representan cada dimensión.	Construye una comparación defendible de participantes y ayuda a explicar por qué se diferencian.
T3	Revisar 19 variables directamente no permite reconocer con facilidad grupos semejantes. La proyección y el agrupamiento sirven para localizar candidatos a perfil.	Detecta concentraciones, separaciones y casos alejados, como C2 con alta actividad total y nocturna.	Responde a la parte del objetivo que busca identificar perfiles y posibles anomalías.
T4	Una forma o un color en el mapa puede inducir a una conclusión incorrecta. Cada grupo debe regresar a las variables originales y a una vista de confirmación.	Determina qué variables explican el perfil, si el patrón se mantiene al controlar cobertura y qué límites tiene.	Completa el objetivo al convertir un grupo visual en conocimiento explicado y comprobado.

4.5. Pipeline del sistema

El flujo general del sistema se resume así:

Datos OpenPlay

- > integracion por participante
- > limpieza y variables derivadas
- > profiling de columnas y cobertura
- > seleccion del vector de características
- > evaluacion de faltantes y correlaciones
- > estandarizacion e imputacion
- > PCA / UMAP / t-SNE
- > clustering exploratorio
- > vistas interactivas y filtros

- > estudios de caso
- > validacion de patrones con variables originales




Figura 2: Pipeline visual de OpenPlay Profiler. El flujo parte del dataset integrado, construye una representación comparable por participante y termina en casos de estudio validados con más de una vista.

Este pipeline permite que el usuario no dependa de una sola salida visual. Cada hallazgo puede contrastarse con la cobertura, el vector, la proyección, la matriz de correlación, la comparación bivariada y la interpretación por variables originales. Por eso el resultado central no es una imagen aislada, sino un conjunto de casos validados: cobertura desigual, intensidad nocturna, bienestar/riesgo con uso registrado y perfil multiplataforma.

5. Diseño visual

La interfaz se organiza en pestañas: Datos, Profiling, Bivariado, Encuestas, Vector, Filtros, PCA/t-SNE/UMAP y Validación. Esta organización sigue el flujo del análisis: primero se entiende el dataset, luego se revisan variables, se construye el vector, se aplican filtros, se proyectan participantes, se interpretan perfiles y finalmente se validan los patrones mediante estudios de caso.

El diseño visual no fue planteado como una colección de gráficos independientes. Cada vista cumple una función dentro del razonamiento analítico. La vista de datos permite decidir si una fuente es confiable; profiling ayuda a revisar calidad de variables; bivariado permite comprobar relaciones específicas; encuestas separa las escalas psicológicas; vector justifica qué atributos entran al modelo; reducción dimensional permite observar perfiles; filtros comprueban si un patrón se mantiene en una submuestra; y validación resume los casos de estudio con evidencia visual.

5.1. Por qué las representaciones visuales permiten descubrir conocimiento

Tabla 9: Justificación analítica de las representaciones visuales

Vista	Representación	Por qué facilita el análisis	Conocimiento que permite obtener
Cobertura	Barras horizontales; fuente en Y y porcentaje en X	La longitud se compara sobre una escala común de 0 a 100. El orden y las etiquetas hacen visibles diferencias grandes entre fuentes.	Distingue fuentes con evidencia amplia de fuentes que representan pocos participantes.
Profiling	Histograma o boxplot más tabla de estadísticos	La posición y longitud muestran distribución y extremos; los valores escritos muestran faltantes y medidas exactas.	Permite decidir si una variable tiene variación, muchos ceros, extremos o cobertura insuficiente.
Bivariado	Punto por participante; variable X, variable Y y color opcional	La posición permite ver si dos variables cambian juntas; el color muestra si un grupo ocupa la misma zona y ayuda a reconocer excepciones.	Comprueba relaciones concretas, como actividad total frente a actividad nocturna.
Correlación	Mapa de calor con color divergente	Colores opuestos separan relaciones positivas y negativas; mayor intensidad indica una relación más fuerte.	Detecta variables que aportan información parecida antes de construir el vector.
PCA/UMAP/t-SNE	Puntos en dos ejes y color por variable o grupo	La distancia resume semejanza en varias variables; el color ayuda a localizar concentraciones, pero la forma se contrasta después con datos originales.	Localiza candidatos a perfil y casos alejados que necesitan explicación.
Perfil de grupos	Barras positivas y negativas respecto al promedio general	Una línea central común permite saber qué variables están por encima o debajo del promedio y comparar grupos.	Explica qué combinación de variables sostiene cada perfil.
Validación	Selector de caso, origen de columnas, transformación, gráfico y vista de confirmación	Hace visible la cadena completa desde los datos hasta el resultado y permite cambiar variables para recalcular.	Permite reproducir el patrón y comprobar que no proviene de una imagen preparada.

5.2. Vistas del sistema

Vista de datos y resumen BI. Presenta participantes, variables, tipos de datos, faltantes promedio y cobertura por fuente. Apoya T1 porque permite saber si un patrón se basa en una fuente con buena cobertura o en pocos registros. Esta vista alimenta directamente el Caso 1, donde la cobertura se convierte en criterio de confiabilidad. La Figura 3 muestra esta vista con el dataset consolidado cargado.




Figura 3: Vista de datos y resumen BI tomada desde el proyecto. La pantalla muestra el dataset consolidado cargado, los indicadores generales y la cobertura por fuente integrada.

Vista de profiling. Muestra estadísticas univariadas, distribuciones, frecuencias y valores faltantes por columna. Apoya T1 y T2 porque ayuda a decidir qué variables son adecuadas para el vector. La Figura 4 muestra esta revisión de columnas dentro de la interfaz.




Figura 4: Vista de profiling tomada desde el proyecto. La interfaz permite inspeccionar columnas, tipos de dato, faltantes, distribuciones y estadísticas descriptivas.

Vista bivariada. Permite comparar dos variables mediante dispersión y color por una tercera variable. Apoya T2 porque permite revisar relaciones entre bienestar, riesgo, telemetría o cognición. Es especialmente importante para validar el Caso 2, donde se contrasta la relación entre sesiones totales y sesiones nocturnas. La Figura 5 muestra la vista usada para explorar relaciones entre pares de variables.




Figura 5: Vista bivariada tomada desde el proyecto. El usuario puede elegir variables para los ejes, colorear por otra dimensión y revisar relaciones antes de interpretar perfiles.

Vista de encuestas e índices. Organiza escalas como GDT, PROMIS, WEMWBS y BANGS. Apoya T2 porque permite interpretar variables psicológicas como dimensiones del vector, no como columnas aisladas. Esta vista respalda el Caso 3, donde las escalas de bienestar y riesgo se analizan junto con registros de uso del tiempo. La Figura 6 muestra la organización de estas escalas en la herramienta.




Figura 6: Vista de encuestas e índices tomada desde el proyecto. La pantalla agrupa medidas de bienestar y riesgo para apoyar la comparación de escalas psicológicas.

Vista de vector de características. Permite seleccionar variables y evaluar cobertura, casos completos y correlaciones altas. Apoya T2 porque ayuda a construir una representación defendible del participante. La Figura 7 muestra el vector recomendado aplicado en el proyecto y la advertencia de correlación usada como apoyo metodológico.




Figura 7: Vista de vector de características tomada desde el proyecto. El sistema muestra el vector recomendado, las variables seleccionadas y una alerta de correlaciones altas para apoyar la selección de atributos.

Vista de filtros. Permite restringir participantes por variables numéricas o categóricas. Apoya T1 y T4 porque permite revisar si un patrón se mantiene dentro de submuestras. Es una vista de control: ayuda a separar patrones de comportamiento de patrones provocados por baja cobertura. La Figura 8 muestra los controles disponibles para restringir la muestra.




Figura 8: Vista de filtros tomada desde el proyecto. Los controles permiten limitar participantes por variables numéricas, categóricas y banderas de disponibilidad antes de validar un patrón.

Vista de reducción dimensional y clustering. Proyecta participantes con PCA, UMAP o t-SNE, colorea por variable o por el perfil oficial, permite selección con click/lazo, calcula métricas visuales y muestra interpretación por variables originales. Apoya T3 y T4. K-means se ejecuta una sola vez sobre las 19 variables originales estandarizadas; las proyecciones 2D reutilizan esas etiquetas y no forman perfiles distintos. Esta vista permite localizar perfiles, pero no se interpreta sola: la explicación de cada grupo se valida con las variables originales. La Figura 9 presenta la evidencia reproducible generada con la ejecución compartida.

Vista de validación. Resume los cuatro estudios de caso del proyecto. Para cada caso muestra pregunta analítica, criterio de selección, variables usadas, patrón encontrado, gráfico de evidencia y explicación de validación. Los gráficos se calculan desde el dataset cargado y reutilizan la ejecución oficial compartida. Además, los accesos de cada caso abren la confirmación correspondiente en Bivariado, Profiling o Filtros. La interacción permite *hover*, selección de puntos, apertura del participante y perfiles agregados. Su propósito es mostrar cómo se obtiene y contrasta conocimiento, no solamente presentar un resultado final.

Tabla 10: Relación entre vistas, interacciones y tareas

Vista	Tipo	Variables re-presentadas	Interacciones	Tareas
Datos / resumen BI	Indicadores y barras de cobertura	Participantes, variables, fuentes, faltantes	Carga de dataset y revisión de resumen	T1
Profiling	Histogramas, tablas y frecuencias	Columnas numéricas y categóricas	Selección de columna, revisión de distribución	T1, T2
Bivariado	Scatter plot y correlación	Dos variables principales y una variable de color	Cambio de ejes, color, tooltip	T2
Encuestas e índices	Descomposición de escalas y heatmap	GDT, PRO-MIS, WEMWBS, BANGS	Selección de variables y comparación de ítems	T2
Vector	Lista de variables, evaluación y recomendaciones	Variables numéricas seleccionadas, cobertura, correlación	Agregar/quitar variables, usar vector recomendado	T2
Filtros	Controles numéricos y categóricos	Variables del dataset y selecciones globales	Filtrar, limpiar filtros, restringir casos	T1, T4
PCA/t-SNE/UMAP	Proyección 2D, clustering y tablas	Coordenadas, color, clusters, variables originales	Zoom, lazo, click, selección de grupos, atípicos y clusters	T3, T4
Validación	Gráficos interactivos y lectura guiada	Cobertura, clusters, bienestar, riesgo, telemetría y uso del tiempo	Hover, click, selección por lazo/caja y perfil agregado	T1, T2, T3, T4

Tabla 11: Relación entre vistas y estudios de caso

Caso de estudio	Vista principal	Vista de confirmación	Conocimiento validado
Cobertura y confiabilidad	Datos / resumen BI	Profiling y filtros	No todas las fuentes tienen la misma fuerza de evidencia; Android, iOS y Xbox requieren cautela.
Intensidad nocturna	PCA/t-SNE/UMAP y clustering	Bivariado e interpretación por variables originales	Existe un perfil con sesiones totales y sesiones nocturnas muy superiores al promedio.
Bienestar, riesgo y uso registrado	Encuestas e índices	Perfil de clusters, filtros y uso del tiempo	Un grupo combina mayor PROMIS, mayor GDT/BANGS, menor WEMWBS y más registros de uso del tiempo.
Perfil multiplataforma	Vector y clustering	Cobertura por fuente y filtros	Un perfil se explica por mayor observabilidad multiplataforma, no solo por intensidad de juego.

5.3. Coordinación entre vistas

La coordinación es importante porque evita interpretar un patrón desde una sola imagen. Por ejemplo, un grupo separado en la proyección puede revisarse con la tabla de variables originales; si además se filtra por cobertura y se compara en la vista bivariada, el usuario puede distinguir entre un perfil real y un efecto producido por datos faltantes. Del mismo modo, un perfil de juego nocturno o un perfil multiplataforma puede contrastarse con las variables originales, las banderas de disponibilidad y los filtros. Esta relación entre vistas convierte el sistema en una herramienta de análisis visual y no solo en un conjunto de gráficos independientes.

El flujo de validación funciona de la siguiente manera. Primero, el usuario identifica una posible separación o concentración en la vista de reducción dimensional. Luego revisa qué variables diferencian al grupo en la tabla de interpretación. Después usa una vista específica, como bivariado, encuestas, cobertura o filtros, para confirmar si el patrón se mantiene. Finalmente, la vista de validación resume el caso con una figura y una lectura concreta. Este flujo responde directamente a la indicación de validar conocimiento mediante varias vistas conectadas.

5.4. Recorrido cognitivo para descubrir conocimiento

El recorrido no comienza con una afirmación cerrada. Primero, el usuario revisa cobertura y faltantes para conocer la fuerza de la evidencia. Segundo, observa una separación en PCA, UMAP o t-SNE y la trata como indicio, no como conclusión. Tercero, selecciona el grupo porque su posición o color sugiere una diferencia relevante. Cuarto, consulta el perfil de variables originales para identificar qué atributos explican esa separación. Quinto, abre una vista de confirmación: dispersión para intensidad nocturna, escalas para bienestar/riesgo o barras para cobertura. Sexto, aplica filtros de disponibilidad y comprueba si el patrón persiste en una submuestra comparable. Finalmente, formula el conocimiento obtenido y declara los límites de la interpretación.

Este orden transforma las interacciones en decisiones analíticas. Seleccionar no es la tarea: se selecciona C2 para comprobar si nocturnidad e intensidad total aumentan conjuntamente. Filtrar tampoco es la tarea: se filtra por disponibilidad para descartar que C3 se explique solo por participantes con más datos. Cambiar el color no es la tarea: se usa el color para verificar si los miembros de un cluster ocupan la misma región cuando se observan variables originales.

6. Discusión, estudios de caso y validación

Esta sección valida la propuesta visual mediante estudios de caso centrados en patrones del problema OpenPlay. No se busca demostrar solamente que dos puntos están cerca o lejos, sino que la herramienta permite explicar comportamientos de juego, cobertura de datos, bienestar y perfiles exploratorios usando varias vistas conectadas.

Para apoyar la validación del informe se incluyen figuras generadas a partir del archivo `openplay_consolidated.csv` y de la exportación `openplay_analysis_run.json`. Esta exportación contiene la configuración y las mismas etiquetas que consume el dashboard. En la aplicación, los gráficos usan esas etiquetas compartidas y permiten inspeccionar puntos, abrir participantes y seleccionar grupos. En el documento, las figuras funcionan como evidencia visual de la misma ejecución, no como un análisis paralelo.

El vector usado para la validación integra variables numéricas de demografía, plataformas, bienestar, riesgo, telemetría, cognición y uso del tiempo. Las variables se preparan antes de aplicar reducción dimensional y clustering, de modo que las diferencias entre participantes no dependan de escalas originales incompatibles.

Para los casos de estudio se utilizó una sola ejecución oficial: vector integral recomendado de 19 variables, imputación por mediana, estandarización, K-means con $k = 4$ sobre el espacio original y semilla 2026. PCA, UMAP y t-SNE no vuelven a formar los perfiles;

funcionan como mapas alternativos donde se colorean las mismas etiquetas. La ejecución guarda participantes, vector, preparación y etiquetas, y es compartida por reducción dimensional, bivariado y validación. Las figuras del informe leen la misma exportación generada por la aplicación. Así, los tamaños y perfiles del documento coinciden con el dashboard.

Como K-means puede intercambiar el número de sus grupos, las etiquetas se ordenan después del cálculo mediante criterios visibles: C0 maximiza cobertura multiplataforma; C1 es el grupo de menor intensidad relativa; C2 maximiza conjuntamente sesiones totales y nocturnas; y C3 maximiza el contraste de bienestar, riesgo y uso registrado. Esta asignación no cambia los integrantes, solo estabiliza el nombre usado para comunicar cada perfil.

Tabla 12: Resumen de patrones encontrados y validación visual

Patrón encontrado	Evidencia usada	Conocimiento validado
Cobertura desigual de fuentes	Variables: <code>has_steam</code> , <code>has_daily</code> , <code>has_cognitive</code> , <code>has_android</code> , <code>has_ios</code> . Vistas: <code>datos</code> , <code>profiling</code> y validación.	No todas las fuentes tienen la misma confiabilidad para interpretar perfiles. Steam, biweekly y cognición sostienen mejor evidencia que Android, iOS o Xbox. Se confirma con cobertura por fuente y revisión de faltantes.
Juego nocturno asociado a intensidad	Variables: <code>telem_nocturnal_sessions</code> , <code>telem_total_sessions</code> . Vistas: bivariado, PCA y clustering.	Los jugadores con más actividad registrada tienden a concentrar más sesiones nocturnas. Se confirma en el scatter bivariado y en el perfil estandarizado de cluster.
Bienestar/riesgo con uso registrado	Variables: <code>promis_total</code> , <code>wemwbs_total</code> , <code>gdt_total</code> , <code>bangs_total</code> , <code>timeuse_gaming_entries</code> . Vistas: encuestas, clustering y validación.	Hay un perfil con mayor riesgo, mayor malestar relativo y más registros de uso del tiempo asociados a videojuegos. Se confirma con medias estandarizadas y filtros de disponibilidad.
Perfil multiplataforma	Variables: <code>num_platforms</code> , <code>num_telemetry_platforms</code> , Steam, Xbox y Nintendo. Vistas: filtros, vector y clustering.	Un grupo se explica por mayor observabilidad y cobertura multiplataforma, no solo por más juego. Se confirma cruzando cobertura por fuente y cluster.




Figura 9: Proyección 2D del vector de características con perfiles exploratorios. La vista permite ubicar grupos y seleccionar participantes; la interpretación se valida con variables originales en las figuras siguientes.




Figura 10: Perfil estandarizado de los clusters. Los valores positivos indican medias del cluster por encima del promedio global y los negativos indican medias por debajo. Esta vista explica qué variables sostienen cada perfil.

6.1. Caso de estudio 1: cobertura de datos y confiabilidad del análisis

Pregunta analítica. ¿Qué fuentes de OpenPlay tienen suficiente cobertura para sostener una interpretación visual y cuáles deben leerse con mayor cautela?

Vistas utilizadas. Vista de datos, resumen BI, profiling, filtros por banderas de disponibilidad y vista de vector de características.

Variables analizadas. `has_steam`, `has_xbox`, `has_nintendo`, `has_android`, `has_ios`, `has_cognitive`, `has_timeuse`, porcentaje de faltantes y tipo de variable.

Interacción. El usuario revisa la cobertura general en la vista de datos, selecciona columnas en profiling para observar faltantes y tipos de dato, y usa filtros por banderas de disponibilidad para comprobar cuántos participantes quedan cuando se exige una fuente específica.

Patrón encontrado. La cobertura no es uniforme entre fuentes. Steam tiene una presencia mucho mayor que Android, iOS o Xbox, mientras que cognición y uso del tiempo tienen cobertura intermedia. Este patrón indica que las conclusiones sobre actividad en Steam pueden apoyarse en más casos, pero las lecturas sobre móviles o Xbox deben tratarse como submuestras con menor representación.




Figura 11: Caso 1: cobertura por fuente integrada en OpenPlay. Steam, biweekly y cognición tienen mayor presencia, mientras que Android, iOS y Xbox aparecen como fuentes de baja cobertura.

Validación cruzada. La Figura 11 muestra que Steam cubre 80.1 % de los participantes, biweekly 62.7 %, cognición 57.1 % y uso del tiempo 44.6 %. En contraste, Xbox cubre 10.9 %, iOS 3.7 % y Android 2.9 %. El profiling confirma el mismo patrón al mostrar faltantes por columna y tipos de dato. La vista de filtros permite restringir el análisis a participantes con una fuente específica y comprobar cuántos casos quedan antes de interpretar una separación o un cluster.

Interpretación. Este caso muestra que el primer conocimiento extraído no es un cluster, sino una advertencia metodológica: la herramienta permite distinguir entre patrones de comportamiento y patrones producidos por disponibilidad desigual de datos.

Validación de la herramienta. La propuesta se valida porque incorpora control de calidad visual antes del modelado. Frente a un análisis exploratorio básico, el sistema no solo calcula gráficos, sino que orienta al usuario sobre qué evidencia es más fuerte y qué evidencia requiere cautela. Por tanto, este caso demuestra que la herramienta no solo visualiza datos, sino que permite validar un patrón mediante la relación entre cobertura, variables originales y vistas coordinadas.

6.2. Caso de estudio 2: juego nocturno e intensidad de actividad

Pregunta analítica. ¿Existe un perfil de participantes cuya separación visual se relacione con mayor intensidad de juego y mayor presencia de sesiones nocturnas?

Vistas utilizadas. Vista PCA/UMAP/t-SNE, color por variable, clustering, tabla de interpretación por variables originales y vista bivariada.

Variables analizadas. `telem_nocturnal_sessions`, `telem_total_sessions`, `xbox_total_sessions`, `nintendo_total_sessions`, `steam_playtime_2weeks_max`, edad y variables de disponibilidad de telemetría.

Interacción. El usuario selecciona las variables de sesiones totales y sesiones nocturnas en la vista bivariada, activa la tendencia, colorea por una escala de riesgo o por cluster, y después contrasta el mismo grupo en la proyección PCA con K-means.

Patrón encontrado. Al colorear la proyección por sesiones nocturnas y luego ejecutar clustering, aparece un grupo cuya interpretación se asocia con mayor cantidad de sesiones totales y mayor presencia de juego nocturno. El patrón no se basa en una sola columna: combina volumen de actividad, horario de juego y presencia de registros de telemetría.




Figura 12: Caso 2: relación entre sesiones totales y sesiones nocturnas. El perfil C2 se concentra en la zona superior derecha, lo que valida que su separación está asociada a mayor intensidad de actividad y mayor presencia de sesiones nocturnas.

Validación cruzada. La Figura 12 compara `telem_nocturnal_sessions` con `telem_total_sessions` y muestra que el perfil C2 se concentra en valores altos de ambas variables. C2 contiene 473 participantes y registra medias de 3056.74 sesiones nocturnas y 6209.46 sesiones totales. La Figura 10 confirma diferencias estandarizadas aproximadas de +0,60 y +0,57, respectivamente, frente al promedio global.

Interpretación. El conocimiento obtenido es la identificación de un perfil exploratorio de mayor intensidad y actividad nocturna. Esta interpretación es relevante porque vincula comportamiento temporal de juego con volumen de uso, sin convertirlo en diagnóstico.

Validación de la herramienta. El caso valida la herramienta porque el patrón se sostiene con proyección, color por variable, vista bivariada e interpretación de cluster. No queda reducido a una impresión visual de la nube de puntos. Por tanto, este caso demuestra que la herramienta no solo visualiza datos, sino que permite validar un patrón mediante la relación entre intensidad de actividad, variables originales y vistas coordinadas.

6.3. Caso de estudio 3: bienestar, riesgo y uso registrado

Pregunta analítica. ¿Existe un perfil donde las variables de bienestar y riesgo se diferencien claramente y, además, se relacionen con mayor registro de uso del tiempo?

Vistas utilizadas. Resumen BI, filtros, vector de características, clustering, tabla de interpretación por variables originales y vista de encuestas.

Variables analizadas. `promis_total`, `wemwbs_total`, `gdt_total`, `bangs_total`, `timeuse_num_days`, `timeuse_gaming_entries`, `has_cognitive`, `has_timeuse` y

has_biweekly.

Interacción. El usuario activa el vector recomendado, revisa las escalas en la vista de encuestas, filtra participantes con datos biweekly y uso del tiempo, y compara las medias estandarizadas del cluster frente al promedio global.

Patrón encontrado. En la interpretación de clusters aparece un perfil con mayor `promis_total`, menor `wemwbs_total`, mayor `gdt_total` y mayor `bangs_total`. El mismo grupo presenta más entradas de uso del tiempo relacionadas con videojuegos y más días registrados. Por tanto, el patrón no es solo psicológico ni solo conductual: combina mayor malestar reportado, mayor riesgo de juego problemático y mayor cantidad de registros de uso del tiempo.




Figura 13: Caso 3: contraste estandarizado de bienestar y riesgo por perfil. El perfil C3 presenta PROMIS, GDT y BANGS por encima del promedio, junto con WEMWBS por debajo del promedio.

Validación cruzada. La Figura 13 confirma el contraste de escalas: C3 se ubica por encima del promedio en PROMIS, GDT y BANGS, y por debajo en WEMWBS. C3 contiene 385 participantes; sus medias son PROMIS 21.84, WEMWBS 21.17, GDT 6.80, 39.40 entradas gaming y 19.02 días de uso del tiempo. La Figura 10 confirma además diferencias positivas en `timeuse_gaming_entries` y `timeuse_num_days`. La vista de encuestas permite revisar estas escalas por separado, mientras los filtros controlan disponibilidad.

Interpretación. Este caso aporta conocimiento porque identifica un perfil que no se explica solo por jugar más o por tener más datos. La combinación de más registros de uso del tiempo con mayor PROMIS, mayor GDT/BANGS y menor WEMWBS sugiere un grupo que merece análisis posterior sobre la relación entre bienestar reportado, riesgo y actividad registrada.

Validación de la herramienta. La herramienta se valida porque permite revisar simultáneamente escalas psicológicas, variables de uso del tiempo, clustering y filtros de disponibilidad. Esto evita presentar el grupo como “jugadores con malestar” sin verificar qué variables sostienen esa lectura. Por tanto, este caso demuestra que la herramienta no solo visualiza datos, sino que permite validar un patrón mediante la relación entre

bienestar, riesgo, uso registrado y vistas coordinadas.

6.4. Caso de estudio 4: perfil multiplataforma con alta cobertura

Pregunta analítica. ¿Qué caracteriza a los participantes con mayor cobertura multiplataforma dentro de la proyección y los clusters?

Vistas utilizadas. Vista de vector de características, evaluación del vector, proyección UMAP, clustering K-means, tabla de clusters e interpretación por variables originales.

Variables analizadas. `num_telemetry_platforms`, `num_platforms`, `has_steam`, `has_xbox`, `has_nintendo`, `timeuse_num_days`, `timeuse_gaming_entries`, `telem_total_sessions` y variables de cobertura.

Interacción. El usuario selecciona el vector recomendado, aplica filtros por número de plataformas o disponibilidad de telemetría, ejecuta clustering K-means y compara la cobertura por fuente entre perfiles.

Patrón encontrado. Con K-means sobre el vector estandarizado se obtuvo un perfil asociado a mayor número de plataformas y mayor número de plataformas con telemetría. Este grupo se diferencia porque no representa solo más tiempo de juego, sino mayor presencia de datos provenientes de varias fuentes. La ejecución oficial contiene: C0 con 569 participantes, C1 con 1117, C2 con 473 y C3 con 385.

Tabla 13: Interpretación de perfiles exploratorios

Perfil	Tamaño	Lectura analítica
C0	569	Mayor número de plataformas declaradas (3.42) y con telemetría (2.03). Se interpreta como perfil multiplataforma con alta cobertura.
C1	1117	Menor intensidad de actividad registrada y menor cobertura de telemetría. Funciona como grupo base de baja intensidad relativa.
C2	473	Mayor cantidad de sesiones nocturnas (3056.74) y totales (6209.46). Se interpreta como perfil de alta intensidad registrada.
C3	385	Mayor GDT, menor WEMWBS y más registros de uso del tiempo relacionados con videojuegos. Se interpreta como contraste de bienestar, riesgo y uso registrado.




Figura 14: Caso 4: cobertura de fuentes por perfil. C0 concentra mayor cobertura Steam y Nintendo; C2 presenta alta cobertura biweekly, cognición y uso del tiempo; y C3 también muestra alta cobertura Steam. Estas diferencias permiten controlar observabilidad al interpretar los perfiles.

Validación cruzada. La interpretación por variables originales confirma que el perfil multiplataforma no es solo un color en el mapa: en la Figura 10, C0 presenta valores positivos fuertes en `num_platforms` y `num_telemetry_platforms`. Además, la Figura 14 muestra que C0 concentra alta cobertura Steam y Nintendo, lo que explica por qué se separa como perfil de mayor observabilidad multiplataforma.

Interpretación. El perfil multiplataforma muestra una explicación distinta a la intensidad: no todos los grupos se separan por jugar más; algunos tienen actividad registrada en más plataformas. Esto aporta más información sobre esas personas, pero también puede hacer que parezcan diferentes solo porque existen más datos sobre ellas.

Validación de la herramienta. Este caso valida la herramienta porque demuestra el flujo completo: vector, proyección, clustering, métricas e interpretación con variables originales. La propuesta visual permite pasar de una nube de puntos a perfiles explicables. Por tanto, este caso demuestra que la herramienta no solo visualiza datos, sino que permite validar un patrón mediante la relación entre cobertura multiplataforma, variables originales y vistas coordinadas.

6.5. Validación de la propuesta visual

La herramienta permite encontrar conocimiento porque transforma datos heterogéneos en una exploración guiada. No se limita a mostrar distribuciones; permite formular preguntas, seleccionar casos, comparar participantes, revisar cobertura y explicar grupos con variables originales.

Las vistas responden a las tareas analíticas planteadas. El resumen BI responde a la calidad de datos; profiling y vector responden a la selección de variables; la matriz de correlación y la vista bivariada responden a relaciones entre variables; la reducción dimensional responde a similitud y separación visual; el clustering responde a perfiles exploratorios; y

la selección coordinada responde a validación de casos.

Los patrones se confirman con más de una visualización. La Figura 9 permite ubicar perfiles; el juego nocturno se explica con la Figura 10 y se comprueba en la Figura 12; el perfil de bienestar y riesgo se revisa en la Figura 13; y el perfil multiplataforma se comprueba en la Figura 14. Comparar varias vistas reduce el riesgo de concluir por una sola imagen.

La interacción entre vistas permite pasar de una pregunta general a un caso concreto. El proceso se puede seguir paso a paso: qué variables se usaron, qué método produjo el mapa, qué grupo se detectó, qué variables lo diferencian y qué límites tiene la interpretación.

7. Matriz de cumplimiento de la rúbrica

La Tabla 14 indica dónde se encuentra la evidencia de cada criterio. Su función es comprobar que la estructura escrita y la validación analítica están conectadas y no dependen de afirmaciones generales.

Tabla 14: Trazabilidad entre la rúbrica y la evidencia del proyecto

Criterio	Exigencia	Evidencia en el informe	Evidencia en la herramienta
A1	Problema, objetivo y justificación	Introducción: perfiles, explicación de diferencias y relevancia social/computacional.	Flujo completo de exploración y validación.
A2	Artículos, análisis crítico, vacío y aporte	Trabajos relacionados y subsección “Vacío identificado y aporte propio”.	Integración de cobertura, vector, perfiles y comprobación.
A3	Base teórica y modelos	Sección Modelos, tablas de entrada/salida y conceptos en lenguaje simple.	PCA, UMAP, t-SNE, K-means, jerárquico y DBSCAN ejecutables.
A4	Datos, preprocesamiento y pipeline	Descripción de 2544 participantes, 171 variables, cobertura, preparación y pipeline.	Carga, profiling, estandarización, tratamiento de faltantes y Web Worker.
A5	Estructura visual	Sección Diseño visual y descripción de datos, tarea, tipo de gráfico e interacción.	Pestañas organizadas según el proceso de análisis.
A6	Mapeo vistas-tareas	Tablas de preguntas, tareas, vistas, interacciones y casos.	Selecciones y filtros compartidos entre vistas.
B1	Justificación de la representación	Tabla “Justificación analítica de las representaciones visuales”.	Ejes, color, barras y perfiles vinculados a variables visibles.

CriterioExigencia		Evidencia en el informe	Evidencia en la herramienta
B2	Necesidad, conocimiento y objetivo por tarea	Tabla “Justificación completa de las tareas analíticas”.	T1–T4 reproducibles en las vistas correspondientes.
B3	Flujo de razonamiento integrado	Pipeline, coordinación de vistas y recorrido cognitivo.	Un grupo seleccionado puede revisarse, filtrarse y validarse en otra vista.
B4	Caso real y validación	Cuatro casos con pregunta, variables, recorrido, patrón, explicación y límites.	Selector de caso que muestra columnas, transformación, gráfico y confirmación.
B5	Patrones propios con evidencia	C0 multiplataforma, C2 intensidad nocturna y C3 bienestar/riesgo, con cifras y figuras.	Gráficos calculados desde el dataset cargado y perfiles por variables originales.

8. Uso responsable de herramientas de inteligencia artificial

Durante el desarrollo se utilizaron herramientas de inteligencia artificial como apoyo para revisar redacción, organizar tareas, detectar posibles errores de código y proponer pruebas. La inteligencia artificial no se utilizó como fuente de los resultados del análisis. Los gráficos y valores presentados se calculan desde el dataset consolidado mediante el código del proyecto.

Para reducir el riesgo de incluir afirmaciones inventadas, se aplicaron cuatro controles. Primero, se comprobó que cada variable mencionada existiera en el dataset; por esa razón no se presentan conclusiones directas sobre ansiedad, depresión, toxicidad u horas de sueño. Segundo, las cifras de los perfiles se contrastaron con el archivo de resumen generado por el proyecto. Tercero, los algoritmos principales y la integración de datos se revisaron con pruebas automáticas. Cuarto, cada patrón se confirmó con más de una vista y se redactó como relación descriptiva, no como causa ni diagnóstico.

La interpretación final corresponde a los integrantes: deben poder explicar qué variables entran en cada gráfico, qué transformación se aplica, qué patrón observan y qué limitación tiene. Si un concepto o resultado no puede explicarse con palabras propias, no debe utilizarse como argumento durante la evaluación.

9. Conclusiones

El proyecto logró construir y validar una herramienta de visualización analítica para explorar el dataset OpenPlay desde una perspectiva multivariada. OpenPlay Profiler integra bienestar, riesgo de juego problemático, telemetría, cognición, plataformas y uso del tiempo en un flujo que va desde la revisión de calidad de datos hasta la interpretación de

perfiles exploratorios. La contribución principal no es solo mostrar una proyección de participantes, sino permitir que cada patrón observado se contraste con variables originales, cobertura y vistas de confirmación.

Las tareas analíticas cubiertas incluyen evaluar cobertura, seleccionar y justificar el vector de características, revisar relaciones entre variables, proyectar participantes, aplicar clustering, interpretar subgrupos y validar hallazgos mediante estudios de caso. Estas tareas se conectan con vistas específicas de la interfaz: datos y profiling para calidad, vector para selección de atributos, bivariado y encuestas para confirmación, reducción dimensional para exploración de grupos, filtros para control de submuestras y validación para sintetizar la evidencia.

Los estudios de caso permitieron validar cuatro hallazgos principales. Primero, la cobertura de fuentes es desigual: Steam, biweekly y cognición ofrecen mayor evidencia, mientras que Android, iOS y Xbox deben interpretarse con cautela. Segundo, existe un perfil de alta intensidad y juego nocturno, confirmado por la relación entre sesiones totales y sesiones nocturnas. Tercero, se identificó un perfil con mayor PROMIS, mayor GDT/BANGS, menor WEMWBS y más registros de uso del tiempo relacionados con videojuegos. Cuarto, se observó un perfil de alta cobertura multiplataforma, explicado por mayor número de plataformas y mayor disponibilidad de telemetría. Estos perfiles no son diagnósticos ni categorías definitivas, sino agrupamientos exploratorios para formular hipótesis.

El diseño visual ayudó a extraer conocimiento porque obligó a validar los patrones desde más de una vista. La proyección 2D permitió ubicar grupos; el perfil estandarizado de clusters explicó qué variables diferenciaban a cada grupo; los gráficos bivariados validaron relaciones específicas como intensidad y nocturnidad; las vistas de encuestas ayudaron a interpretar bienestar y riesgo; y la cobertura por fuente permitió distinguir entre comportamiento observado y disponibilidad desigual de datos. Esta coordinación reduce el riesgo de concluir solo por la forma de una nube de puntos.

Entre las limitaciones se encuentran la alta presencia de valores faltantes, la cobertura desigual por plataforma, la dependencia del vector seleccionado, el uso de imputación para completar variables y la sensibilidad de PCA, UMAP, t-SNE y clustering a sus parámetros. La versión final ya compara estabilidad y diferencia el clustering oficial en el espacio original de las comparaciones 2D. Como mejoras futuras se propone validar los perfiles con nuevas muestras, incorporar pruebas estadísticas por variable, enriquecer el diccionario de datos y permitir guardar anotaciones de los analistas sobre cada caso.

10. Referencias

Referencias

- [1] Ballou, N., Földes, T. A., Vuorre, M., Hakman, T., Magnusson, K., & Przybylski, A. K. (2025). *Open Play: A longitudinal dataset of multi-platform video game digital trace data and psychological measures*. PsyArXiv. <https://osf.io/preprints/psyarxiv/nz96c>
- [2] World Health Organization. (2020). *Addictive behaviours: Gaming disorder*. <https://www.who.int/news-room/questions-and-answers/item/>

- [3] Keim, D. A., Mansmann, F., Schneidewind, J., Thomas, J., & Ziegler, H. (2008). Visual analytics: Scope and challenges. En S. J. Simoff, M. H. Böhlen & A. Mazeika (Eds.), *Visual data mining* (pp. 76–90). Springer.
- [4] Heer, J., & Shneiderman, B. (2012). Interactive dynamics for visual analysis. *Communications of the ACM*, 55(4), 45–54.
- [5] Munzner, T. (2014). *Visualization analysis and design*. CRC Press. Cap. 3: Why: Task Abstraction.
- [6] Jolliffe, I. T. (2002). *Principal component analysis* (2nd ed.). Springer.
- [7] McInnes, L., Healy, J., & Melville, J. (2018). *UMAP: Uniform Manifold Approximation and Projection for dimension reduction*. arXiv. <https://arxiv.org/abs/1802.03426>
- [8] van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.
- [9] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. En *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281–297).