

OpenPlay Profiler: análisis visual, vector de características y clustering

Juan José Huamaní Vásquez
Zela Flores Gabriel Frank

22 de junio de 2026

1. Introducción

El análisis de datos sobre videojuegos y bienestar requiere integrar distintas fuentes de información para comprender mejor el comportamiento de los participantes. En el dataset OpenPlay no solo se registran respuestas de encuestas, sino también variables asociadas a telemetría, actividad diaria, bienestar, riesgo de juego problemático, cognición y uso del tiempo. Por esta razón, analizar una sola variable de forma aislada no es suficiente para identificar patrones relevantes.

La herramienta *OpenPlay Profiler* fue desarrollada para facilitar este proceso mediante un flujo de análisis visual. Primero permite cargar y revisar el dataset consolidado; luego ayuda a construir y evaluar un vector de características; posteriormente aplica reducción de dimensionalidad para representar a los participantes en dos dimensiones; finalmente, permite ejecutar clustering para identificar perfiles exploratorios de jugadores.

La parte más importante del análisis es la selección del vector de características, porque este define cómo se representa cada participante antes de aplicar UMAP y K-means. En este trabajo se utiliza un vector integral que combina variables demográficas, bienestar, riesgo de juego problemático, telemetría, actividad diaria, cognición y uso del tiempo. Esto permite obtener una representación más completa del comportamiento de los participantes.

Los clusters obtenidos no deben interpretarse como diagnósticos ni como categorías definitivas. Son grupos exploratorios formados por similitud entre participantes dentro de la proyección bidimensional. Por ello, la interpretación de cada grupo se realiza revisando también las variables originales que más diferencian a cada cluster.

2. Objetivo

Analizar el dataset OpenPlay mediante una herramienta interactiva que permita construir un vector de características, proyectar a los participantes en dos dimensiones y aplicar clustering para identificar perfiles exploratorios de jugadores.

3. Metodología

El proceso seguido en la herramienta se organizó en cinco etapas:

1. **Carga de datos:** se utilizó el archivo consolidado `openplay_consolidated.csv`.
2. **Profiling:** se revisaron variables, tipos de datos, valores faltantes y estadísticas descriptivas.
3. **Vector de características:** se seleccionó un vector integral recomendado para representar el proyecto.
4. **Reducción dimensional:** se aplicó UMAP para obtener una proyección en dos dimensiones.
5. **Clustering:** se aplicó K-means con cuatro grupos sobre la proyección UMAP.

4. Vector de características

El vector seleccionado integra variables de distintas dimensiones del dataset. Esta selección permite representar a cada participante desde una perspectiva amplia, evitando que el análisis dependa únicamente de variables de salud mental o de telemetría.

Cuadro 1: Dimensiones consideradas en el vector de características

Dimensión	Variables representativas
Base del participante	Edad, número de plataformas, número de plataformas con telemetría.
Bienestar y salud mental	WEMWBS, PROMIS.
Riesgo de juego problemático	GDT, BANGS.
Telemetría de juego	Sesiones totales, sesiones nocturnas, tiempo de juego en Steam, juegos únicos.
Actividad diaria	Días jugados, días con estrés reportado.
Cognición	Precisión media y tiempo de respuesta medio.
Uso del tiempo	Entradas relacionadas con juego y número de días registrados.



Figura 1: Selección y evaluación del vector de características.

5. Resultados de clustering

Para la segmentación se utilizó K-means sobre la proyección UMAP. La herramienta detectó cuatro grupos con una distribución razonable de participantes, por lo que pueden analizarse como perfiles exploratorios.

Cuadro 2: Distribución de participantes por cluster

Cluster	Participantes	Centro X	Centro Y
Cluster 3	1079	0.405	-1.943
Cluster 2	560	0.563	2.419
Cluster 4	487	3.370	0.404
Cluster 1	418	-0.018	-6.215




Figura 2: Proyección UMAP con clustering K-means de cuatro grupos.

5.1. Interpretación de los clusters

Los ejes UMAP 1 y UMAP 2 no representan variables originales, sino una síntesis visual de similitud entre participantes. Por ello, cada cluster debe interpretarse como un grupo de participantes con patrones similares dentro del vector de características.

- **Cluster 3: perfil central o mayoritario.** Es el grupo más grande, con 1079 participantes. Representa el perfil más común dentro del dataset y sirve como referencia para comparar los demás grupos.
- **Cluster 2: perfil diferenciado en la zona superior de UMAP.** Cuenta con 560 participantes. Su ubicación indica que comparte características que lo separan del perfil central, por lo que debe revisarse si presenta diferencias en bienestar, riesgo de juego problemático, estrés o intensidad de juego.
- **Cluster 4: perfil separado hacia la derecha de la proyección.** Incluye 487 participantes. Esta separación puede estar asociada a diferencias en telemetría, actividad de juego, tiempo de juego o cantidad de plataformas utilizadas.
- **Cluster 1: perfil inferior de la proyección.** Contiene 418 participantes. Al tener un tamaño considerable, no se interpreta como un caso atípico aislado, sino como un perfil exploratorio con características distintas al resto.

Grupo	Participantes	Centro X	Centro Y
Cluster 2	815	1.079	-4.078
Cluster 3	635	-1.250	0.709
Cluster 1	598	-1.693	-4.329
Cluster 4	496	4.035	-0.613

Interpretación por variables originales			
Grupo	Variables que mas lo diferencian		
Cluster 2 (815)	timeuse_num_days: +0.78 σ	num_telemetry_platforms: -0.48 σ	self_reported_weekly_play: -0.39 σ
	steam_playtime_2weeks_min: -0.38 σ	steam_playtime_2weeks_max: -0.38 σ	
	Lectura rapida Se diferencia sobre todo por timeuse_num_days alto respecto al promedio.		
Cluster 3 (635)	num_telemetry_platforms: +1.16 σ	telem_nocturnal_sessions: +0.71 σ	telem_total_sessions: +0.70 σ
	num_platforms: +0.62 σ	timeuse_num_days: +0.58 σ	
	Lectura rapida Se diferencia sobre todo por num_telemetry_platforms alto respecto al promedio.		
Cluster 1 (598)	timeuse_gaming_entries: +0.94 σ	steam_playtime_2weeks_min: +0.86 σ	steam_playtime_2weeks_max: +0.86 σ
	self_reported_weekly_play: +0.66 σ	steam_playtime_forever_max: +0.61 σ	
	Lectura rapida Se diferencia sobre todo por timeuse_gaming_entries alto respecto al promedio.		
Cluster 4 (496)	timeuse_num_days: -0.95 σ	timeuse_gaming_entries: -0.72 σ	cog_mean_rt: +0.63 σ
	num_telemetry_platforms: -0.43 σ	cog_mean_accuracy: -0.58 σ	
	Lectura rapida Se diferencia sobre todo por timeuse_num_days bajo respecto al promedio.		

σ indica cuantas desviaciones estandar se aleja la media del cluster de la media global. Valores positivos son mas altos que el promedio; negativos, mas bajos.

Lectura: si un grupo contiene casi todos los puntos y los demas tienen 1 o 2 casos, no son perfiles; son atípicos. Para defender perfiles, busca grupos con tamanos razonables y diferencias interpretables en variables originales.

Figura 3: Interpretación de clusters mediante variables originales del vector.